

基于随机森林的多因子选股模型构建

——金融工程专题报告

分析师：王雪莹

SAC NO: S1150525020001

2025 年 6 月 30 日

证券分析师

王雪莹

022-23839121

wangxy4430@bhq.com

核心观点：

● 多因子模型与随机森林介绍

- 多因子模型通过选取一组影响资产收益率的因子，并建立因子与收益率之间的数学模型，来解释和预测资产的收益率，应用于复杂多变的金融市场时，常因其对市场关系的线性假设而显得力不从心。随机森林模型无需预设因子与收益间的函数关系，而是通过算法驱动的方式，自动学习和发现数据中隐藏的复杂结构，通过集成大量决策树，能够精准捕捉非线性关系与高阶交互作用。将随机森林等机器学习模型应用于多因子选股，是传统量化投资向“AI 量化”升级的典型路径，能够穿透市场表面的噪音，从高维、非结构化的数据中解构和识别复杂的非线性模式、捕捉转瞬即逝的市场微观结构特征，并构建能够动态适应市场环境变化的自适应模型。

● 模型构建

- 模型构建中选取了包含估值因子、成长因子、质量因子、杠杆因子、市值因子、动量反转因子、换手率因子、技术因子等八个类别的 25 个基本面和技术面因子。将 2010.1.4 至 2025.4.30 整个时间段的后 40% 作为回测区间，前 60% 的数据中，80% 作为训练集，剩下 20% 作为测试集。选取中证 500 指数成分股作为基准股票池，每 20 个交易日进行一次调仓，每次选择 10 只股票持有，先后进行了特征和标签提取、数据预处理、训练集和测试集的合成、模型训练和模型回测步骤。
- 结果显示，随机森林模型大幅跑赢了中证 500 指数。从收益指标来看，随机森林模型的总收益率、年化收益率、Sharpe、Calmar 等均高于基准，波动率和最大回撤都低于基准，风险收益比远好于基准，说明经过历史数据的学习，随机森林模型具有更优异的选股能力和更稳定的表现。随机森林模型凭借其强大的非线性建模能力和抗噪性，在多因子选股策略中实现了更优的风险调整后收益，验证了机器学习方法在量化交易中的实用价值。
- 风险提示：模型基于历史数据构建，存在失效的风险，不构成投资建议。第三方数据不准确的风险。

目 录

1. 多因子模型和随机森林算法介绍.....	4
2. 模型构建	7
3. 模型回测	11
4. 总结	13

图 目 录

图 1: 训练集箱体图	9
图 2: 测试集箱体图	9
图 3: 回测集箱体图	10
图 4: 策略表现与基准对比	11

表 目 录

表 1: 多因子模型和随机森林选股模型的对比.....	5
表 2: 参数设置	7
表 3: 因子列表	7
表 4: 策略表现与基准对比	11

1. 多因子模型和随机森林算法介绍

多因子模型是现代金融学中用于解释和预测资产收益率的重要工具之一。该模型认为资产的收益率是由多个因子共同决定的，通过多因子模型，可以更全面地了解资产的内在价值，从而更好地进行投资决策。多因子模型通过选取一组影响资产收益率的因子，并建立因子与收益率之间的数学模型，来解释和预测资产的收益率。可以理解为将股票的收益率分解为 k 个因子的线性组合和未被因子解释的残差项。

$$r_i = \sum_k \beta_{ik} f_k + \varepsilon_i$$

r_i 为股票 i 的预期收益率

β_{ik} 为股票 i 对 k 因子的敏感度

f_k 为 k 因子的预期收益率

ε_i 为残差

构建一个传统的多因子模型通常遵循一个清晰、线性的流程：1. 因子挖掘与定义：基于经济学理论和市场经验，定义并计算一系列因子；2. 数据预处理：对因子数据进行清洗、去极值、标准化和中性化等处理；3. 单因子有效性检验：使用 IC（信息系数）分析和分层回测等方法，检验每个单独的因子是否具有预测能力，并剔除无效因子；4. 多因子合成：将通过检验的多个有效因子进行组合，最常见的方法是：等权重法（简单地给每个因子相同的权重）、IC 加权法（根据因子历史 IC 的均值或 IR 值来分配权重，表现越好的因子权重越高）、线性回归法（用历史收益率对多个因子做回归，得到的回归系数作为因子的权重）；5. 组合构建与回测：基于因子构建投资组合，进行历史回测并评估策略表现。

随机森林（Random Forest）是一种强大的集成学习算法，其核心思想根植于“集体智慧优于个体”的原则。它并非构建一个单一、复杂的决策模型，而是通过创建成百上千个简单且各不相同的决策树，并将它们的预测结果进行汇总，来得出最终的决策。这种方法论的精髓在于，通过聚合大量“普通但多样”的个体判断，

能够有效地中和掉单一模型的偏差和方差,从而得到一个远比任何个体都更准确、更稳健的最终结果。

随机森林在构建过程中巧妙引入的“双重随机性”机制,这保证了森林中每一棵树的独特性。首先,它采用自助采样法(Bagging),为每棵树随机地、有放回地从原始数据集中抽取一部分样本进行训练,这确保了各棵树的学习基础不同。其次,在每棵树的生长过程中,当需要在节点进行分裂时,它会从所有特征中随机选取一个子集,并只在这个子集中寻找最优分裂特征。这两个随机过程的结合,极大地降低了树与树之间的相关性,从而有效地防止了模型对训练数据的过拟合。

当面对一个新的预测任务时,随机森林会启动一个民主的决策流程。它将新数据传递给森林中的每一棵决策树,让它们各自独立地给出一个预测。对于分类任务,最终结果由所有树的投票来决定;对于回归任务,则通过计算所有树预测值的平均值来确定。这种聚合策略不仅提升了预测的准确性,更重要的是,它使得模型对数据中的噪声和异常值具有很强的鲁棒性,从而确保了预测结果的稳定和可靠。

表 1: 多因子模型和随机森林选股模型的对比

对比维度	多因子模型	随机森林选股模型
思想基础	理论驱动	数据驱动
关系假设	线性关系	非线性关系与交互关系
模型可解释性	高	低
因子处理	依赖人工处理	机器自动学习
信息利用	经验总结	最大化数据信息

资料来源: 渤海证券研究所

传统的投资决策框架,无论是依赖于宏观叙事的基本面分析,还是基于历史图表的技术分析,其效力都因市场的日益有效和“阿尔法”的快速衰减而受到侵蚀。量化模型常因其对市场关系的线性假设而显得力不从心。在此背景下,机器学习的崛起,不仅是技术工具的迭代,更是量化投资领域一次深刻的范式革命。它赋予我们一种全新的能力,能够穿透市场表面的噪音,从高维、非结构化的数据中解构和识别复杂的非线性模式、捕捉转瞬即逝的市场微观结构特征,并构建能够动态适应市场环境变化的自适应模型,为新一代多因子选股策略的构建奠定了坚实的基础。将随机森林等机器学习模型应用于多因子选股,是传统量化投资向“AI量化”升级的典型路径。它与传统线性模型的根本区别在于,它能够捕捉因子与收益之间复杂的非线性关系和因子间的交互效应。

随机森林模型无需预设因子与收益间的函数关系,而是通过算法驱动的方式,自动学习和发现数据中隐藏的复杂结构。通过集成大量决策树,能够精准捕捉非线性

性关系与高阶交互作用；而梯度提升树则通过迭代优化，逐步逼近最优预测函数。更重要的是，现代机器学习框架内置的正则化技术和交叉验证机制，为我们提供了对抗过拟合这一量化建模核心风险的系统性工具，从而显著提升了模型的稳健性与泛化能力。

2. 模型构建

策略选取中证 500 指数成分股作为基准股票池，每 20 个交易日进行一次调仓，选择 10 只股票持有。2010.1.4 至 2025.4.30 整个时间段的后 40%作为回测区间，前 60%的数据中，80%作为训练集，剩下 20%作为测试集。

表 2: 参数设置

参数名称	参数设置
股票池	中证 500 指数成分股
基准	中证 500 指数
调仓频率	每 20 个交易日
持仓股票数	10 只
训练时间	2010.1.4 至 2017.5.5
测试时间	2017.6.6 至 2019.3.25
回测时间	2019.4.23 至 2025.4.30

资料来源：渤海证券研究所

模型构建中选取了包含估值因子、成长因子、质量因子、杠杆因子、市值因子、动量反转因子、换手率因子、技术因子等八个类别的 25 个基本面和技术面因子。

表 3: 因子列表

因子类别	因子名称
估值因子	利润市值比
	账面市值比
	营收市值比
	现金流市值比
成长因子	营业收入增长率
	净利润增长率
	经营现金流量净额增长率
质量因子	权益回报率
	资产回报率
	销售毛利率
	销售净利率
	总资产周转率
	净利润现金含量
杠杆因子	债务总资产比
	长期负债总资产比
	现金比率
	流动比率
市值因子	对数市值

动量反转因子	20 日变动速率
	60 日变动速率
	beta
换手率因子	20 日平均换手率
	60 日平均换手率
技术因子	MACD/收盘价
	MFI

资料来源：渤海证券研究所

构建过程如下：

1. 特征和标签提取：

每 20 个交易日，计算 25 个因子暴露度，作为样本的原始特征；计算下一期个股相对基准的超额收益，作为样本的标签。

2. 数据预处理


将数据进行异常值和缺失值处理、并进行标准化，随后进行主成分分析。

3. 训练集和测试集的合成

选取下一期收益排前、后 30% 的股票分别作为正例、负例，合成训练集和测试集。


下面展示了训练集、测试集和回测集的箱体图，观察发现，经过数据预处理后，数据变得更规整，近似服从标准正态分布，符合机器学习对数据集的要求。

图 1: 训练集箱体图




资料来源: 聚宽, 渤海证券研究所

图 2: 测试集箱体图



资料来源: 聚宽, 渤海证券研究所

图 3: 回测集箱体图



资料来源: 聚宽, 渤海证券研究所

4. 模型训练


将经过预处理的训练集数据放入随机森林模型进行训练,并在测试集上进行检验。

结果显示,模型在训练集上的正确率较高,能达到 62.93%,而测试集上则较低些,但仍有 52.46%,说明模型有一定的预测效果。

3. 模型回测

利用训练好的模型在回测集上进行预测并进行策略回测，下图展示了收益曲线与绩效指标。结果表明，在 6 年多的时间内，随机森林模型大幅跑赢了中证 500 指数。从收益指标来看，随机森林模型的总收益率、年化收益率、Sharpe、Calmar 等均高于基准，波动率和最大回撤都低于基准，风险收益比远好于基准，说明经过历史数据的学习，随机森林模型具有更优异的选股能力和更稳定的表现。

图 4：策略表现与基准对比



资料来源：聚宽，渤海证券研究所

表 4：策略表现与基准对比

	收益率	年收益率	波动率	Sharpe	最大回撤	Calmar
随机森林	153.64%	17.03%	21.35%	0.7974	20.78%	0.8195
中证 500	-0.91%	-0.15%	21.87%	-0.0070	41.81%	-0.0037

资料来源：聚宽，渤海证券研究所

随机森林模型在预测准确性和收益表现上显著优于基准。首先，随机森林作为集成学习方法，能够有效捕捉市场数据的非线性特征和复杂模式，减少过拟合风险。其次，在回测中，随机森林模型通过多维度特征（如技术指标、波动率、市场情绪等）的融合，展现出稳定的超额收益和更低回撤。此外，随机森林的参数调优空间大，可通过特征选择和样本平衡进一步优化性能。总结下来，随机森林模

型凭借其强大的非线性建模能力和抗噪性，在多因子选股策略中实现了更优的风险调整后收益，验证了机器学习方法在量化交易中的实用价值。

4. 总结

多因子模型通过选取一组影响资产收益率的因子，并建立因子与收益率之间的数学模型，来解释和预测资产的收益率，应用于复杂多变的金融市场时，常因其对市场关系的线性假设而显得力不从心。随机森林模型无需预设因子与收益间的函数关系，而是通过算法驱动的方式，自动学习和发现数据中隐藏的复杂结构，通过集成大量决策树，能够精准捕捉非线性关系与高阶交互作用。将随机森林等机器学习模型应用于多因子选股，是传统量化投资向“AI 量化”升级的典型路径，能够穿透市场表面的噪音，从高维、非结构化的数据中解构和识别复杂的非线性模式、捕捉转瞬即逝的市场微观结构特征，并构建能够动态适应市场环境变化的自适应模型。

模型构建中选取了包含估值因子、成长因子、质量因子、杠杆因子、市值因子、动量反转因子、换手率因子、技术因子等八个类别的 25 个基本面和技术面因子。将 2010.1.4 至 2025.4.30 整个时间段的后 40% 作为回测区间，前 60% 的数据中，80% 作为训练集，剩下 20% 作为测试集。选取中证 500 指数成分股作为基准股票池，每 20 个交易日进行一次调仓，每次选择 10 只股票持有，先后进行了特征和标签提取、数据预处理、训练集和测试集的合成、模型训练和模型回测步骤。

结果显示，随机森林模型大幅跑赢了中证 500 指数。从收益指标来看，随机森林模型的总收益率、年化收益率、Sharpe、Calmar 等均高于基准，波动率和最大回撤都低于基准，风险收益比远好于基准，说明经过历史数据的学习，随机森林模型具有更优异的选股能力和更稳定的表现。随机森林模型凭借其强大的非线性建模能力和抗噪性，在多因子选股策略中实现了更优的风险调整后收益，验证了机器学习方法在量化交易中的实用价值。

风险提示:

1.模型基于历史数据构建，存在失效的风险，不构成投资建议。本模型基于历史数据构建，未来有失效的风险，不构成对投资者的投资建议。

2.第三方数据不准确的风险。本报告数据来源为第三方数据平台，可能存在延迟、缺失等情况，可能对报告结论产生一定的影响。

分析师声明:

本报告署名分析师在此声明: 我们具有中国证券业协会授予的证券投资咨询执业资格并登记为证券分析师, 以勤勉尽责的职业态度、专业审慎的研究方法, 使用合法合规的数据和信息, 独立、客观地出具本报告; 本报告所表述的任何观点均精准地、如实地反映研究人员的个人观点, 结论不受任何第三方的授意或影响。我们所获取报酬的任何部分无论是在过去、现在及将来均不会与本报告中的具体投资分析意见或观点有直接或间接的联系。

风险提示及免责声明:

投资者应自主作出投资决策并自行承担投资风险, 任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。

本报告由渤海证券股份有限公司(以下简称“本公司”)制作, 仅供本公司的客户使用。发送本报告不构成任何合同或承诺的基础, 不因接收者收到本报告而视其为本公司客户。本报告仅在相关法律许可的情况下发送, 并仅为提供信息而发送, 不构成任何广告。

本报告的信息来源于已公开的资料, 本公司对该等信息的准确性、完整性或可靠性不作任何保证, 不保证该信息未经任何更新。本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断, 本报告所指的证券或投资标的的价格、价值及投资收入可升可跌。过往表现不应作为日后表现的依据。在不同时期, 本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司不保证本报告所含信息保持在最新状态。同时, 本公司对本报告所含信息可在不发出通知的情形下做出修改, 投资者应当自行关注相应的更新或修改。在任何情况下, 本报告内容的全部或部分均不构成对任何人的投资建议。本报告中所指的投资及服务可能不适合个别客户, 不构成客户私人咨询建议。在任何情况下, 本公司、本公司员工或者关联机构不承诺投资者一定获利, 不与投资者分享投资收益, 也不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。投资者务必注意, 其据此做出的任何投资决策与本公司、本公司员工或者关联机构无关。在任何情况下, 本公司、本公司员工或者关联机构不就本报告中的任何内容对任何投资做出任何形式的担保。

在所知情的范围内, 本公司、本报告撰写人以及财产上的利害关系人与本报告所评价或作出明确估值和投资评级的证券无利害关系。本公司利用信息隔离墙控制内部一个或多个领域、部门或关联机构之间的信息流动。因此, 投资者应注意, 在法律许可的情况下, 本公司及其所属关联机构可能持有并交易本报告中所提公司的股份或其他财产权益, 也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。市场有风险, 投资需谨慎。投资者不应将本报告作为作出投资决策的唯一参考因素, 亦不应认为本报告可以取代自己的判断。在决定投资前, 如有需要, 投资者务必向专业人士咨询并谨慎决策。

本报告版权为本公司所有。未经本公司事先书面许可, 任何机构和/或个人不得以任何形式刊载、转发、翻版、复制、发布或引用本报告全部或部分内容, 亦不得从未经本公司书面授权的任何机构、个人或其运营的媒体平台接收、翻版、复制或引用本报告全部或部分内容。如征得本公司同意进行引用、刊载或转发的, 需在允许的范围内使用, 并注明出处为“渤海证券股份有限公司”且不得对本报告进行任何有悖原意的引用、删节和修改。

若本公司以外的其他机构(以下简称“该机构”)发送本报告, 则由该机构独自为此发送行为负责。通过此途径获得本报告的投资者应自行联系该机构以要求获悉更详细信息或进而交易本报告中提及的证券。本报告不构成本公司向该机构之客户提供的投资建议, 本公司、本公司员工或者关联机构亦不为该机构之客户因使用本报告或报告所载内容引起的任何损失承担任何责任。

投资评级说明:

项目名称	投资评级	评级说明
公司评级标准	买入	未来 6 个月内相对沪深 300 指数涨幅超过 20%
	增持	未来 6 个月内相对沪深 300 指数涨幅介于 10%~20%之间
	中性	未来 6 个月内相对沪深 300 指数涨幅介于-10%~10%之间
	减持	未来 6 个月内相对沪深 300 指数跌幅超过 10%
行业评级标准	看好	未来 12 个月内相对于沪深 300 指数涨幅超过 10%
	中性	未来 12 个月内相对于沪深 300 指数涨幅介于-10%-10%之间
	看淡	未来 12 个月内相对于沪深 300 指数跌幅超过 10%

渤海证券研究所机构销售团队:
高级销售经理: 朱艳君

座机: +86 22 2845 1995

手机: 135 0204 0941

邮箱: zhuyanjun@bhqz.com

天津:

天津市南开区水上公园东路宁汇大厦 A 座写字楼

邮政编码: 300381

电话: +86 22 2845 1888

传真: +86 22 2845 1615

高级销售经理: 王文君

座机: +86 10 6810 4637

手机: 186 1170 5783

邮箱: wangwj@bhqz.com

北京:

北京市西城区西直门外大街甲 143 号 凯旋大厦 A 座 2 层

邮政编码: 100086

电话: +86 10 6810 4192

传真: +86 10 6810 4192

 渤海证券股份有限公司网址: www.ewww.com.cn